

Lipschitz 常数小为什么允许更大的学习率

核心结论：若目标函数的梯度是 L -Lipschitz 连续的，则梯度下降中保证单步下降的学习率通常满足

$$0 < \eta < \frac{2}{L}.$$

因此， L 越小，允许的学习率上界越大。

1 问题设定

考虑目标函数 $f(x)$ ，梯度下降的更新规则为

$$x_{t+1} = x_t - \eta \nabla f(x_t),$$

其中 η 是学习率。

假设 f 的梯度是 L -Lipschitz 连续的，即

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|.$$

这意味着梯度变化不会超过输入变化的 L 倍。 L 越小，梯度场越平滑。

2 下降引理

由梯度 Lipschitz 连续可得 f 是 L -smooth 函数，并满足下降引理：

$$f(y) \leq f(x) + \nabla f(x)^\top (y - x) + \frac{L}{2} \|y - x\|^2.$$

这个不等式说明：在点 x 附近，函数值可以被一个一阶项加二次误差项控制。二次误差项中的 L 决定了函数曲面的最大弯曲程度。

3 代入梯度下降更新

令

$$y = x - \eta \nabla f(x).$$

代入下降引理：

$$\begin{aligned} f(x - \eta \nabla f(x)) &\leq f(x) + \nabla f(x)^\top (-\eta \nabla f(x)) + \frac{L}{2} \|\eta \nabla f(x)\|^2 \\ &= f(x) - \eta \|\nabla f(x)\|^2 + \frac{L\eta^2}{2} \|\nabla f(x)\|^2 \\ &= f(x) - \eta \left(1 - \frac{L\eta}{2}\right) \|\nabla f(x)\|^2. \end{aligned}$$

4 学习率条件

为了保证目标函数下降，需要

$$\eta \left(1 - \frac{L\eta}{2}\right) > 0.$$

由于 $\eta > 0$ ，因此只需

$$1 - \frac{L\eta}{2} > 0.$$

于是得到

$$\eta < \frac{2}{L}.$$

因此，允许的最大学习率与 Lipschitz 常数 L 成反比：

$$\eta_{\max} \propto \frac{1}{L}.$$

5 更保守的常用选择

实际分析中常用更保守的学习率范围：

$$0 < \eta \leq \frac{1}{L}.$$

此时

$$1 - \frac{L\eta}{2} \geq \frac{1}{2},$$

因此有更清晰的下降量下界：

$$f(x - \eta \nabla f(x)) \leq f(x) - \frac{\eta}{2} \|\nabla f(x)\|^2.$$

6 直观解释

- L 小：梯度变化平缓，函数曲面较光滑，可以迈更大的步。
- L 大：梯度变化剧烈，函数曲面更陡或更弯，步长过大容易震荡或发散。
- 因此，Lipschitz 常数越小，理论上允许的稳定学习率越大。